

INTRODUÇÃO

A interoperabilidade no setor de saúde enfrenta uma série de barreiras, como a heterogeneidade tecnológica, a ausência de padronização de dados e os elevados custos operacionais envolvidos na integração de sistemas distintos (Fennely O, 2024). Esse cenário torna-se ainda mais complexo diante do crescimento exponencial de dados não estruturados como anotações clínicas, evoluções de enfermagem e laudos, que, apesar de conterem informações valiosas, permanecem amplamente subutilizados pela dificuldade de processamento e integração entre hospitais, clínicas e laboratórios.

A capacidade de analisar grandes volumes de dados já demonstrou impulsionar avanços significativos, como a identificação de fatores de risco cardiovascular e a detecção precoce de neoplasias (Beam Al, 2018; Esteva A, 2019). No entanto, o aproveitamento efetivo desse potencial depende diretamente da capacidade de superar as limitações atuais de interoperabilidade e integração de informações clínicas, especialmente em ambientes com infraestrutura heterogênea.

O obstáculo central reside no fato de que o conhecimento clínico mais relevante está "preso" em textos livres. O estado atual do processamento desses dados ainda depende de trabalho manual, moroso e sujeito a inconsistências (Hossain E, 2023). As abordagens computacionais tradicionais de Processamento de Linguagem Natural (PLN), baseadas em pipelines de Extração Transformação e Carga (ETL) e modelos clássicos de Machine Learning (ML), mostraram-se insuficientes para lidar com a complexidade e a variedade de jargões dos registros eletrônicos de saúde, exigindo grande esforço de engenharia de dados e apresentando limitações de adaptabilidade (Naseem U, 2021).

Essa lacuna é ampliada por desafios tanto sistêmicos quanto éticos. Embora padrões como o *Fast Healthcare Interoperability Resources* (FHIR) (HL7, 2025) busquem aprimorar a interoperabilidade, sua adoção ainda é desigual, o que dificulta a consolidação de uma abordagem unificada para a estruturação de dados. Ao mesmo tempo, a proteção da privacidade dos dados do paciente permanece uma preocupação central, mas ainda são escassos os estudos que investigam de forma sistemática os riscos de segurança e proponham estratégias robustas de mitigação (Naseem U, 2021).

A otimização da terapia nutricional, por exemplo, exige a análise de informações detalhadas como comorbidades, sinais de desconforto e o racional por trás de decisões médicas que, em grande parte, permanecem dispersas em notas de evolução não estruturadas. A ausência de integração efetiva entre esses registros e ferramentas especializadas, como o sistema DaN-DataOnNutrition®, não apenas compromete a continuidade do cuidado, mas também inviabiliza o uso de processos automatizados capazes de extrair e consolidar essas

informações. A superação desse gargalo requer soluções que permitam a captura e o processamento automatizado dessas informações de forma padronizada e confiável (Shi J, 2019, Rajendran S, 2020), garantindo ao mesmo tempo estrita conformidade com regulamentações de privacidade.

Diante desse cenário, percebe-se à ausência de uma abordagem que seja, ao mesmo tempo, flexível para lidar com a heterogeneidade dos textos, interoperável entre diferentes sistemas e segura para proteger a privacidade do paciente.

Nos últimos anos, os avanços em Processamento de Linguagem Natural (PLN) aplicado aos Registros Eletrônicos de Saúde conhecidos como *Electronic Health Records* (EHRs) têm ampliado o potencial de análise de textos clínicos não estruturados, apoiando tarefas como classificação e codificação automática por meio dos sistemas ICD-9/10. Esses sistemas padronizam diagnósticos e procedimentos médicos em códigos, facilitando a organização, análise e comunicação de informações clínicas. Com o uso de PLN, é possível atribuir esses códigos automaticamente a partir de textos médicos, agilizando processos e tornando a linguagem técnica mais acessível. Modelos de aprendizado profundo, mostraram desempenho superior em tarefas como reconhecimento de entidades clínicas, previsão de risco e extração de informações contextuais (Naseem U, 2021).

Ainda assim, a revisão sistemática de (Naseem U, 2021). evidencia que a aplicação dessas tecnologias ao domínio da saúde enfrenta limitações importantes: a escassez de dados anotados de forma consistente, o desafio de balanceamento de classes, a ausência de estratégias consistentes e amplamente testadas para proteção de dados sensíveis, e a carência de metodologias padronizadas para avaliação e validação dos modelos. Além disso, embora arquiteturas como o *Bidirectional Encoder Representations from Transformers* (BERT), um modelo de linguagem baseado em redes neurais que processa o contexto das palavras de forma bidirecional, permitindo melhor compreensão semântica e suas variantes clínicas apresentem ganhos significativos em acurácia e capacidade de generalização, sua adoção em cenários reais ainda demanda mecanismos de transparência dos modelos, mitigação de erros (como as “alucinações”) e integração segura com sistemas já existentes. Nesse contexto, abre-se espaço para investigar soluções que combinem tais avanços com estratégias de recuperação de informações, curadoria humana e anonimização, de modo a transformar o potencial técnico em valor clínico efetivo.

Para suprir essa ausência, este trabalho propõe uma abordagem baseada na hipótese de que large language models (LLM), com sua capacidade de aprendizado com poucos exemplos (*few-shot prompting*), aliada ao uso de Retrieval-Augmented Generation (RAG), oferecem uma oportunidade para superar as limitações das abordagens anteriores (Jimma BL, 2022; SARAIVA, 2023). A ênfase recai na construção de um processo de contextualização e

recuperação de informações capaz de transformar dados clínicos não estruturados em conhecimento utilizável.

Este trabalho propõe uma estratégia baseada em LLMs para extrair, contextualizar e integrar de forma segura informações clínicas não estruturadas. O diferencial está na capacidade de contextualização semântica, permitindo que dados dispersos em prescrições, laudos e prontuários sejam convertidos em informações estruturadas, interoperáveis e relevantes para apoiar decisões clínicas, reduzir redundâncias e melhorar a continuidade do cuidado.

A proposta contempla a definição de um processo de extração e contextualização de informações voltado à estruturação de dados clínicos. Esse processo incorpora requisitos de segurança e anonimização alinhados às normas de privacidade, além de mecanismos de validação que permitem analisar a consistência e a utilidade das informações geradas em diferentes cenários de uso.