

UNIVERSIDADE DO ESTADO DA BAHIA - UNEB
DEPARTAMENTO DE CIÊNCIAS EXATAS E DA TERRA - Campus I
COLEGIADO DE SISTEMAS DE INFORMAÇÃO

ALANA CAROLINA PEREIRA ABREU

Desenvolvimento de estratégias de teste de software com IA generativa: integração entre LLM-as-a-Judge e Human-in-the-Loop

ANTEPROJETO

SALVADOR
2026

ALANA CAROLINA PEREIRA ABREU

Desenvolvimento de estratégias de teste de software com IA generativa: integração entre LLM-as-a-Judge e Human-in-the-Loop

Anteprojeto apresentado ao componente
Sistemas de informação do curso de sistemas da Informação,
Universidade do Estado da Bahia.
Orientador: Eduardo Manuel de Freitas Jorge

SALVADOR
2026

1. Introdução

A utilização de sistemas de inteligência artificial (IA) baseados em modelos de linguagem tem se ampliado em atividades que envolvem análise, classificação e interpretação de informações. Em aplicações voltadas a domínios especializados, esses sistemas podem produzir diferentes tipos de resultados, como classificações, informações estruturadas e textos, tornando sua avaliação mais complexa do que a simples verificação de respostas exatas.

Nesse contexto, estratégias de avaliação baseadas em LLM-as-a-Judge têm sido investigadas como uma alternativa para avaliar aspectos semânticos e textuais das respostas geradas por sistemas de IA. Entretanto, estudos apontam que a avaliação realizada por modelos de linguagem pode apresentar divergências em relação à avaliação de especialistas humanos, especialmente em tarefas que exigem conhecimento específico do domínio. Szymanski et al. (2024), por exemplo, identificaram diferenças entre avaliações realizadas por LLMs e especialistas em tarefas de conhecimento especializado.

Outra abordagem investigada na literatura é a construção de conjuntos de avaliação específicos para determinados domínios. Raju et al. (2024) destacam a importância de conjuntos de avaliação que representem adequadamente as características das aplicações avaliadas, enquanto Ferreira, Silva e Oliveira (2024) investigam estratégias para avaliação de conhecimento de modelos de linguagem utilizando conjuntos de dados específicos de domínio.

Diante desse cenário, esta pesquisa propõe investigar uma estratégia de avaliação para sistemas de IA especializados, combinando um conjunto de casos de referência construído com participação de especialistas, avaliações determinísticas e LLM-as-a-Judge. Como estudo de caso, será considerado um sistema de análise documental baseado em inteligência artificial, buscando analisar a aplicabilidade e as limitações dessa abordagem na avaliação de seus resultados.

O trabalho está inserido nas áreas de Inteligência Artificial, Processamento de Linguagem Natural e Engenharia de Software, com foco na avaliação de sistemas baseados em modelos de linguagem.

2. Problema de pesquisa

A avaliação de sistemas de inteligência artificial especializados apresenta desafios relacionados à diversidade e à natureza dos resultados produzidos. Enquanto determinados resultados podem ser verificados por meio de regras e comparações objetivas, outros dependem de aspectos semânticos e de conhecimento específico do domínio. Dessa forma, uma única estratégia de avaliação pode não ser suficiente para analisar adequadamente diferentes características das respostas produzidas.

A utilização de LLM-as-a-Judge pode auxiliar na avaliação de aspectos textuais e semânticos, mas estudos existentes demonstram que os julgamentos realizados por modelos

de linguagem podem divergir das avaliações de especialistas humanos. Ao mesmo tempo, conjuntos de avaliação específicos por domínio podem fornecer referências para comparações mais sistemáticas, mas sua construção e utilização em conjunto com diferentes métodos de avaliação ainda apresentam desafios.

Além disso, sistemas de IA podem sofrer alterações ao longo de seu desenvolvimento, seja pela modificação de modelos, prompts, regras, configurações ou bases de conhecimento. Sem um conjunto de casos de referência previamente definido, torna-se mais difícil acompanhar de forma sistemática possíveis alterações nos resultados produzidos pelo sistema.

Diante disso, esta pesquisa busca investigar uma estratégia que combine referências definidas por especialistas, avaliações determinísticas e LLM-as-a-Judge para avaliar sistemas de inteligência artificial especializados.

Questão principal de pesquisa:

Como uma estratégia baseada em casos de referência validados por especialistas, combinada a avaliações determinísticas e LLM-as-a-Judge, pode contribuir para a avaliação de sistemas de inteligência artificial especializados?

3. Objetivos

3.1. Objetivo geral

Propor e avaliar uma estratégia para avaliação de sistemas de inteligência artificial especializados, combinando casos de referência validados por especialistas, avaliações determinísticas e LLM-as-a-Judge.

3.2. Objetivos específicos

1. Realizar uma revisão da literatura sobre avaliação de sistemas de inteligência artificial especializados e utilização de LLM-as-a-Judge;
2. Caracterizar o sistema de inteligência artificial utilizado como estudo de caso e os principais tipos de resultados produzidos;
3. Construir um conjunto de casos de referência com resultados esperados definidos e validados por especialistas;
4. Aplicar uma estratégia de avaliação combinando métodos determinísticos e LLM-as-a-Judge aos resultados produzidos pelo sistema;
5. Analisar os resultados obtidos, considerando a concordância com as referências dos especialistas, as divergências identificadas e as limitações da estratégia proposta.

4. Justificativa

A utilização de sistemas de inteligência artificial em atividades que envolvem análise e interpretação de informações especializadas torna necessária a adoção de estratégias capazes de avaliar a qualidade e a adequação dos resultados produzidos. Essa necessidade é ampliada em sistemas que apresentam diferentes tipos de saída, nos quais parte dos resultados

pode ser verificada objetivamente, enquanto outros dependem de aspectos semânticos e do conhecimento do domínio.

Do ponto de vista científico, a pesquisa contribui para os estudos relacionados à avaliação de sistemas baseados em modelos de linguagem, especialmente pela investigação da utilização de LLM-as-a-Judge em conjunto com referências construídas a partir de avaliações humanas. Trabalhos existentes apontam tanto o potencial de conjuntos de avaliação específicos por domínio quanto limitações na concordância entre avaliações realizadas por LLMs e especialistas, indicando a necessidade de investigar estratégias de avaliação adequadas a diferentes contextos.

Do ponto de vista tecnológico e profissional, a proposta pode contribuir para processos de desenvolvimento e manutenção de sistemas de inteligência artificial, fornecendo uma abordagem para acompanhar a qualidade dos resultados e identificar divergências após alterações no sistema. A utilização de casos de referência também pode favorecer avaliações mais sistemáticas e comparáveis entre diferentes execuções.

A pesquisa será realizada utilizando um sistema real de análise documental como estudo de caso, permitindo investigar a estratégia em um contexto de aplicação prática. Embora o estudo esteja delimitado a esse contexto, os procedimentos investigados poderão fornecer subsídios para sua adaptação a outros sistemas de inteligência artificial que apresentem características semelhantes.

A realização do trabalho também é viável devido à disponibilidade do sistema utilizado como estudo de caso, dos recursos tecnológicos necessários para sua avaliação e da possibilidade de contar com especialistas para a definição e validação dos casos de referência. Dessa forma, a pesquisa poderá concentrar-se na investigação da estratégia de avaliação, sem a necessidade de desenvolver um novo sistema de inteligência artificial.

5. Metodologia

A pesquisa terá caráter aplicado e exploratório, sendo desenvolvida a partir de um estudo de caso envolvendo um sistema de inteligência artificial especializado em análise documental. O trabalho será realizado em etapas, que poderão ser ajustadas ao longo da pesquisa conforme os resultados da revisão da literatura e a definição do desenho experimental.

Inicialmente, será realizada uma revisão da literatura sobre avaliação de sistemas de inteligência artificial especializados, conjuntos de casos de referência, avaliação humana e utilização de LLM-as-a-Judge. Essa etapa terá como finalidade identificar abordagens, critérios e limitações relevantes para a definição da estratégia de avaliação.

Em seguida, será caracterizado o sistema utilizado como estudo de caso, considerando os tipos de documentos analisados e os diferentes resultados produzidos. A partir dessa caracterização, será construído um conjunto de casos de referência, ou *golden dataset*, composto por casos representativos do domínio, seus resultados esperados e os critérios necessários para sua avaliação. Esses resultados serão definidos e validados com a participação de especialistas do domínio, de modo que o conjunto possa ser utilizado como referência para comparar diferentes execuções do sistema.

Posteriormente, os casos de referência serão utilizados para avaliar os resultados produzidos pelo sistema. Para informações estruturadas ou passíveis de verificação objetiva, serão utilizadas comparações determinísticas. Para resultados textuais ou que dependam de interpretação semântica, será utilizada a abordagem LLM-as-a-Judge. Dessa forma, a pesquisa buscará investigar uma estratégia que combine referências humanas e métodos automatizados de avaliação, analisando a concordância entre os resultados e as divergências identificadas.

Por fim, os resultados serão analisados por meio de indicadores adequados aos diferentes tipos de saída avaliados. Também será investigado se a estratégia permite identificar alterações nos resultados produzidos pelo sistema em diferentes execuções. Os resultados obtidos serão discutidos considerando as características do estudo de caso, as limitações da abordagem e sua possível aplicação em outros sistemas de inteligência artificial especializados.

Referências

FERREIRA, Bruno Carlos Luís; SILVA, Catarina; OLIVEIRA, Hugo Gonçalo. *Towards automated evaluation of knowledge encoded in large language models.* In: WORKSHOP ON DEEP LEARNING AND LINKED DATA (DLnLD) @ LREC-COLING, 2024, Torino. Proceedings of the Workshop on Deep Learning and Linked Data (DLnLD) @ LREC-COLING 2024. Torino: ELRA and ICCL, 2024. p. 76–85. Disponível em: https://aclanthology.org/2024.dlnld-1.7/. Acesso em: 24 set. 2026.

RAJU, Ravi Shanker; JAIN, Swayambhoo; LI, Bo; LI, Jonathan Lingjie; THAKKER, *Urmish. Constructing domain-specific evaluation sets for LLM-as-a-judge.* In: WORKSHOP ON CUSTOMIZABLE NLP: PROGRESS AND CHALLENGES IN CUSTOMIZING NLP FOR A DOMAIN, APPLICATION, GROUP, OR INDIVIDUAL (CustomNLP4U), 1., 2024, Miami. Proceedings of the 1st Workshop on Customizable NLP: Progress and Challenges in Customizing NLP for a Domain, Application, Group, or Individual (CustomNLP4U). Miami: Association for Computational Linguistics, 2024. p. 167–181. Disponível em: https://aclanthology.org/2024.customnlp4u-1.14/. Acesso em: 24 set. 2026.

SZYMANSKI, Annalisa; ZIEMS, Noah; EICHER-MILLER, Heather A.; LI, Toby Jia-Jun; JIANG, Meng; METOYER, Ronald A. *Limitations of the LLM-as-a-judge approach for evaluating LLM outputs in expert knowledge tasks*. arXiv, 2024. Disponível em: https://arxiv.org/abs/2410.20266. Acesso em: 24 set. 2026.